Отчет о выполнении исследовательского проекта

Постановка задачи

Гипотеза: разные модели и разные стратегии конкурентоспособны на разных участках прогнозного горизонта.

Цель работы: оценить качество статистических бейзлайнов и глобальных моделей машинного/глубокого обучения не только по усредненной метрике на всем горизонте, но и в разрезе каждого отдельного шага прогнозирования, а также сравнить рекурсивную (Recursive) и прямую (Direct) стратегии для CatBoost.

Распределение ролей

Проект выполнялся в команде из двух человек:

- **Каюмов Вадим:** парсинг и предобработка .tsf датасета, настройка пайплайна для бейзлайнов, реализация глобальной рекурсивной стратегии для CatBoost, агрегация результатов предсказаний в единый датафрейм, написание отчета.
- **Садулаев Идрис:** имплементация глобальной Direct-стратегии для CatBoost (ввиду ограничений стандартных библиотек), настройка и обучение PatchTST, расчет метрик, визуализация результатов и создание репозитория.

Описание данных

В качестве основы использован датасет *M4 Forecasting Competition (Monthly)*.

- **Объем выборки:** 150 уникальных временных рядов (макроэкономические, демографические и финансовые показатели). Ряды имеют различную длину (в среднем около 235 наблюдений на ряд).
- **Горизонт прогнозирования:** 18 шагов (1.5 года).

Для формирования лагов использовалось окно истории равное 24 месяцам.

Методология эксперимента

Все прогнозы оценивались в исходной шкале данных. Для деревьев решений применялись ненормированные данные (в силу их устойчивости к масштабу признаков). В случае PatchTST применялась динамическая нормализация и обратная денормализация.

Для валидации использовался hold-out метод, последние 18 точек каждого временного ряда были выделены в тестовую выборку.

Поскольку в эксперименте участвует набор из 150 различных временных рядов с разными масштабами значений, использование абсолютных метрик представляется нецелесообразным. Основной метрикой выбрана **sMAPE** (*Symmetric Mean Absolute Percentage Error*). Для компенсации асимметричности sMAPE рассчитывалась **WAPE** (*Weighted Absolute Percentage Error*).

Описание моделей

В эксперименте зафиксированы 4 бейзлайна и 3 вариации глобальных моделей:

Статистические бейзлайны (StatsForecast):

- **Naive:** наивный прогноз (последнее известное значение).
- **SeasonalNaive:** сезонный наивный прогноз (сдвиг на 12 месяцев).
- **AutoETS:** алгоритм автоматизированного экспоненциального сглаживания, который раскладывает временной ряд на три ключевых компонента: ошибку, тренд и сезонность.
- **AutoTheta:** статистический метод декомпозиции, который разделяет временной ряд на компоненты (долгосрочный тренд и краткосрочные колебания), автоматически подбирая параметр (θ) для модификации кривизны тренда.

Глобальные модели:

- **CatBoost_Recursive:** вариация градиентного бустинга, обученная на 150 рядах с рекурсивной стратегией. Прогноз строится итеративно: предсказание на шаг t используется как признак для шага $t+1$.
- **CatBoost_Direct:** вариация градиентного бустинга, обученная на 150 рядах с прямой стратегией. Обучено 18 независимых моделей (по одной на каждый шаг горизонта). Каждая модель предсказывает свой шаг h напрямую из исторических данных.
- **PatchTST (NeuralForecast):** глобальная модель на базе архитектуры Transformer. Настроена с учетом ограничений памяти (max_steps=200 и revin=True).

Результаты

Глобальные метрики на всем горизонте

Модель	sMAPE, %	WAPE, %
AutoTheta	13.84	13.74
AutoETS	14.17	14.49
CatBoost_Direct	15.28	14.99
CatBoost_Recursive	14.61	15.01
Naive	15.42	15.84
PatchTST	15.54	16.03
SeasonalNaive	16.56	16.53

Динамика ошибки на разных участках прогнозного горизонта

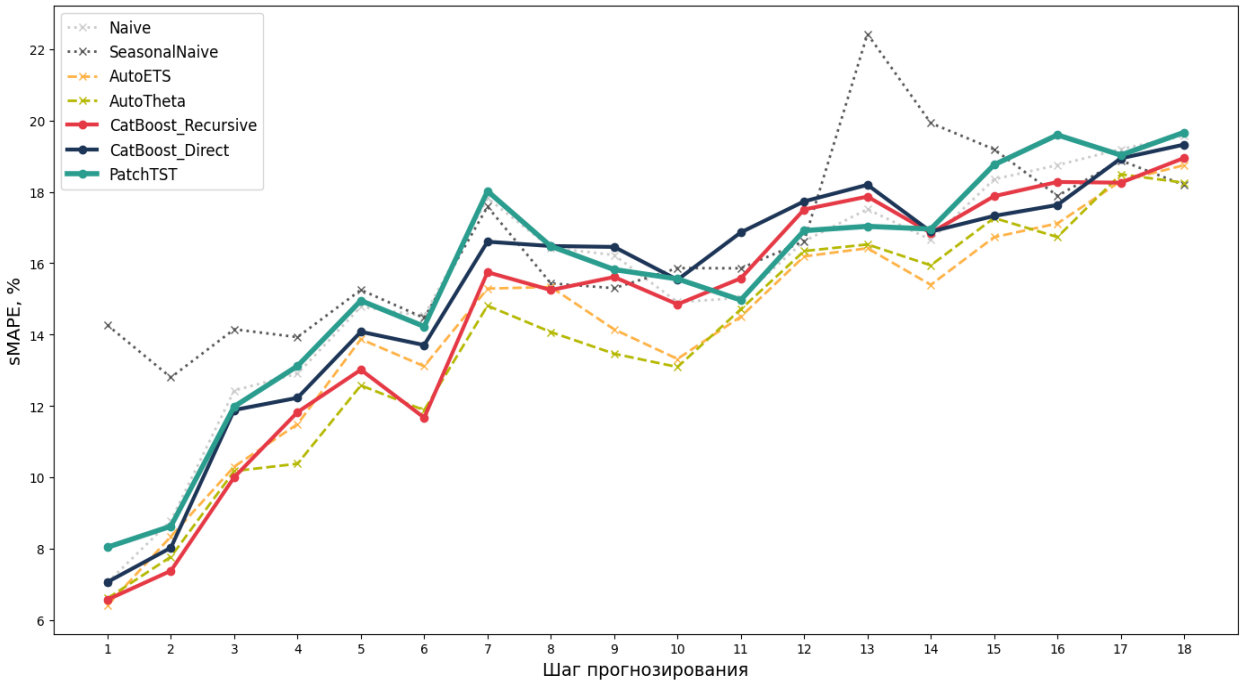

Конкурентоспособность на разных участках прогнозного горизонта (sMAPE)

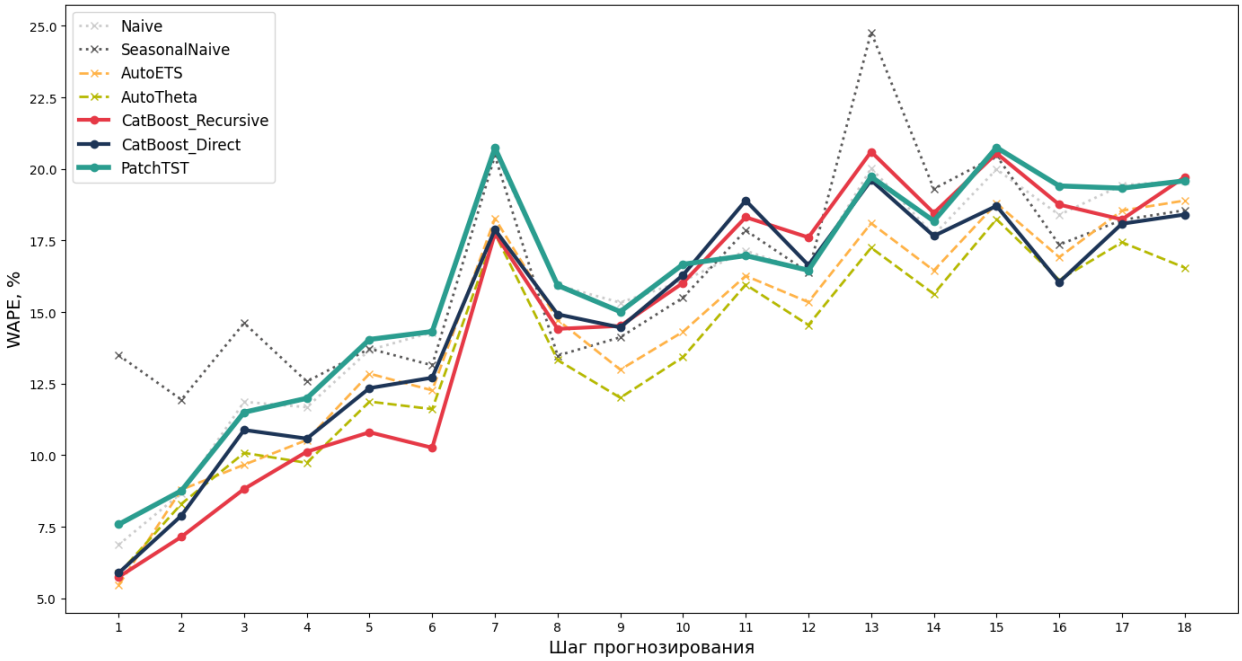

Конкурентоспособность на разных участках прогнозного горизонта (WAPE)

Выводы

Анализ графиков и таблиц позволяет сделать следующие выводы, которые **подтверждают исходную гипотезу**:

1. **Статистические модели лучше на длинной дистанции:** классические методы AutoTheta и AutoETS оказались победителями эксперимента на всем горизонте. Начиная с 4-го шага, они демонстрируют наименьшую ошибку и наибольшую устойчивость. Имея заданную структуру (тренд + сезонность), они хорошо экстраполируют паттерны.

2. **Градиентный бустинг выигрывает на коротких горизонтах:** на первых 1–3 шагах горизонта стратегия CatBoost_Recursive показывает лучшие результаты, конкурируя за лидерство с AutoTheta по sMAPE, а по взвешенной метрике WAPE является лидером на шагах с 1 по 6. Деревья решений отлично улавливают нелинейные локальные тренды в моменте.

3. **Накопление ошибки влияет на качество рекурсивной стратегии на длинном горизонте:** на усредненной метрике sMAPE стратегия Direct уступила Recursive. Однако анализ графика WAPE выявил важную закономерность: на дальних горизонтах (шаги 14–18) стратегия Direct обходит рекурсивную. Рекурсивный подход страдает от накопления ошибки, что приводит к сильным промахам в физических объемах прогноза (WAPE). В таких условиях прямая стратегия, прогнозируя шаг независимо, сохраняет более точный масштаб предсказаний.

4. **Модели глубокого обучения проседают на малых данных:** нейросеть PatchTST показала слабую конкурентоспособность, уступив градиентному бустингу и бейзлайнам. Архитектуре трансформера не хватает 150 коротких временных рядов для успешной сходимости механизма внимания.